

چارچوب‌های نظری و تجربی یادگیری تقویتی عمیق

نسخه فارسی گزارش جامع

مخزن درس یادگیری تقویتی عمیق

۲۴ بهمن ۱۴۰۴

فهرست مطالب

۱	هدف گزارش
۲	چگونه بازتولید کنیم
۲	۳ زنجیره ۱: روش‌های مبتنی بر ارزش، Dueling Double، (DQN)
۳	۴ زنجیره ۲: گرادیان سیاست و ناحیه اعتماد، CPO-lite) TRPO، PPO، (REINFORCE
۴	۵ زنجیره ۳: بازیگر-ناظر و آنتروپی بیشینه، SAC) (A^{π_C}/A^{π_C}
۴	۶ زنجیره ۴: مبتنی بر مدل، ME-TRPO) (Dyna-Q
۵	۷ زنجیره ۵: چندعامله، MADDPG) (QMIX
۵	۸ جمع‌بندی

۱ هدف گزارش


این سند نسخه فارسی گزارش پروژه است و تمام زنجیره‌های پنج‌گانه‌ی مقاله‌ها (مبتنی بر ارزش، گرادیان سیاست، بازیگر-ناظر، مبتنی بر مدل، و چندعامله) را پوشش می‌دهد. هر بخش شامل توضیح نظری کوتاه، تنظیمات آزمایش، و جدول نتایج قابل پرشدن است.

۲ چگونه بازتولید کنیم

- محیط مجازی: `python3.10 venv -m` `source` `venv` `..venv_runs/bin/activate` سپس
- نصب وابستگی‌ها: `requirements.txt -r install pip`
- `python scripts/run_experiment.py -seed- 20000 -steps- -v1CartPole -env- dqn -algo- value -chain- scripts/run_experiment.py -mode- configs/suites/fast_5chain.yaml -suite- scripts/run_suite.py` کل سوئیت:
- `python scripts/generate_plots.py` ساخت نمودار و جدول: سپس `python scripts/build_report_tables.py`
- خروجی‌ها در `outputs/runs` و `outputs/suite_reports` ذخیره می‌شوند.

۳ زنجیره ۱: روش‌های مبتنی بر ارزش (DQN، Double، Dueling)

ایده اصلی: بازپخش تجربه، شبکه هدف، کاهش سوگیری بیش‌برآورد با Double و نمایش بهتر با Dueling. **تنظیمات پیشنهادی برای CartPole:** نرخ یادگیری 10^{-3} ، `train_freq=1`، اندازه بافر `50k` اپسیلون نهایی `0.02`، `total_steps=100k` (پر شود):




شکل ۱: نمودار یادگیری زنجیره ارزش (تولید خودکار).

الگوریتم	گام‌ها	بازده میانگین	انحراف معیار
DQN			
DQN Double			
DQN Dueling			
QR-DQN (اختیاری)			

۴ زنجیره ۲: گرادیان سیاست و ناحیه اعتماد، (REINFORCE، PPO، TRPO، CPO-lite)

توضیح کوتاه: REINFORCE با پایه، TRPO با قید، PPO KL با برش نسبت احتمال، نسخه ساده CPO با جریمه لاگرانژی هزینه. جدول نتایج:




شکل ۲: نمودار یادگیری روش‌های سیاست‌محور (تولید خودکار).

الگوریتم	محیط	گام‌ها	بازده میانگین	هزینه میانگین
REINFORCE				
PPO				
TRPO				
CPO-lite				

۵ زنجیره ۳: بازیگر-ناظر و آنتروپی بیشینه، A^2C/A^3C (SAC)

توضیح کوتاه: A^2C به عنوان جایگزین سبک A^3C SAC با آنتروپی خودکار برای کنترل پیوسته. جدول نتایج:




شکل ۳: نمودار یادگیری بازیگر-ناظر (تولید خودکار).

الگوریتم	گام‌ها	بازده میانگین	انحراف معیار
proxy) (A^3C A^2C			
SAC			

۶ زنجیره ۴: مبتنی بر مدل، Dyna-Q، ME-TRPO)

توضیح کوتاه: Dyna-Q با بهروزرسانی‌های برنامه‌ریزی؛ ME-TRPO با مدل تجمیع چندگانه برای کاهش سوگیری مدل. جدول نتایج:

الگوریتم	محیط	معیار	مقدار
Dyna-Q	CliffWalking-v۰	میانگین ۱۰۰ اپیزود آخر	
ME-TRPO	Pendulum-v۱	بازده ارزیابی	



شکل ۴: نمودار یادگیری زنجیره مدل محور (تولید خودکار).


۷ زنجیره ۵: چندعامله، QMIX، MADDPG)

توضیح کوتاه: QMIX با تابع اختلاط یکنوا، MADDPG با منتقد متمرکز و بازیگر غیرمتمرکز. جدول نتایج:

الگوریتم	تکرار	پاداش اپیزود میانگین
QMIX		
MADDPG		

۸ جمع بندی

پس از اجرای سوئیت، این فایل را با `report_fa.tex -xelatex latexmk` کامپایل کنید. برای جمع بندی، تفاوت پایداری، کارایی نمونه، ایمنی و مقیاس پذیری بین پنج زنجیره را بر اساس جدول ها و نمودار های تولیدی تحلیل کنید.



شکل ۵: نمودار یادگیری چندعامله (تولید خودکار).