## يادگيري تقويتي

نيمسال بهار ۴۰۲-۱۴۰۱

اساتید: دکتر رهبان، آقای حسنی



مدت: ۲۰ دقیقه کوییز ۲ تاریخ: ۱۴ اسفند

شماره دانشجويي:

نام و نام خانوادگي:

## سوال ۱: سوال توضيحي (۴۰ نمره)

- (آ) یکی از روشهای کاهش واریانس در روشهای بهینهسازی سیاست، کم کردن یک baseline از پاداش تجمیعی است. توضیح دهید چگونه با این تفریق تغییری در متوسط گرادیان تابع هزینه نسبت به پارامترهای تابع سیاست رخ نمیدهد. (با نوشتن رابطه اثبات شود.)
- (ب) چالش الگوریتم tabular Q-learning در محیطهای با فضای حالت پیوسته چیست؟ توضیح دهید شبکه (tabular Q-learning چگونه قادر است بر این مشکل غلبه کند.

## سوال ۲: الگوريتم REINFORCE (۶۰ نمره)

تصور کنید در یک محیط با فضای حالت پیوسته عامل تنها دو حرکت راست و چپ را دارد. همچنین در نظر بگیرید که تابع سیاست توسط شبکه عصبی ای با پارامتر  $\theta$  محاسبه می شود: (تصور شود که مقدار  $\phi(s,a)$  برای هر جفت حالت\_کنش به صورت یک عدد به ما داده شده است.)

$$\pi_{\theta}(a|s) = \frac{\exp(\theta^{\top}\phi(s, a))}{\sum_{a'} \exp(\theta^{\top}\phi(s, a'))}$$

تابع پاداش نیز به صورت زیر بدست می آید:

$$R(s,a) = \begin{cases} -s^2 & , a = Left \\ s^2 & , a = Right \end{cases}$$

- (آ) رابطه بروزرسانی تابع سیاست با الگوریتم REINFORCE را بنویسید.
- (+) تصور کنید مسیر زیر به طول T=3 توسط عامل طی شده و حال میخواهد تابع سیاست خود را بروز کند:

$$s_1 = 0.5, a_1 = Left$$

$$s_2 = -0.8, a_2 = Right$$

$$s_3 = 0.2, a_3 = Right$$

گرادیان تابع سیاست را با استفاده از مسیر طی شده و فرمول نوشته شده بخش (آ) محاسبه کنید. ضریب تخفیف  $(\gamma)$  را 0.9 در نظر بگیرید.