

AMASA-Complex v2: چارچوب پیشرفته و پیکربندی محور برای یادگیری تقویتی امن در بخیه‌زنی خودکار

Codex

/Users/tahamajs/Documents/uni/DRL/projects/amasa_clean

IV. مدل محیط و سناریوها

رابط مسئله ثابت مانده است:

- حالت ۲۳ بعدی
- کنش ۷ بعدی گشتاور
- پاداش ترکیبی (شکل‌دهی + تکمیل)
- هزینه برای نقض محدودیت نیرو/کریدور

سناریوها:

- Nominal: نویز ملایم
- Perturbed: نویز و شیفت دینامیکی قوی‌تر
- Adversarial: خرابی مشاهده و تاخیر شدیدتر

V. مجموعه الگوریتم‌ها

آ. آفلاین

(۱) CQL: کاهش بیش‌برآورد روی کنش‌های خارج از توزیع با جمله محافظه‌کارانه:

$$\mathcal{L}_{critic} = \mathcal{L}_{TD} + \alpha_{CQL} \mathcal{L}_{cons}$$

(۲) IQL: ترکیب expectile value fitting و advantage-weighted policy update برای استخراج سیاست آفلاین پایدار.

ب. آنلاین امن

(۱) SAC-Lagrangian: تابع هدف سیاست:

$$\mathcal{L}_{\pi} = \mathbb{E}[\alpha \log \pi(a|s) - Q_r(s, a) + \lambda Q_c(s, a)]$$

(۲) PPO-Lagrangian: مزیت ترکیبی:

$$\hat{A}_{\lambda} = \hat{A}_r - \lambda \hat{A}_c$$

با clipping و برآورد جداگانه‌ی مزیت پاداش/هزینه.

VI. پشته ایمنی ترکیبی

ترتیب اجرای نگهبان ایمنی:

- (۱) پیشنهاد کنش توسط سیاست
 - (۲) امتیاز ریسک توسط منتقد ریسک
 - (۳) تبدیل محافظه‌کارانه در ریسک بالا
 - (۴) عبور از سپر تصمیم‌درختی
 - (۵) اجرای کنش نهایی در محیط
 - (۶) به‌روزرسانی λ با کنترل‌گر PID
- ثبت ایمنی در هر گام: 'risk_score', 'lambda', 'corridor_violation', 'force', 'cost', 'shield_blocked'

VII. تنظیم آزمایش‌ها

آ. ماتریس بنچمارک

با بذرها $\{0, 1, 2\}$:

- آفلاین: CQL و IQL روی nominal و perturbed
- آنلاین: SAC-Lagrangian و PPO-Lagrangian روی هر سه سناریو

تعداد کل اجراها: ۳۰.

چکیده—این گزارش نسخه‌ی AMASA-Complex v2 را ارائه می‌کند که نسبت به نسخه‌ی اولیه، پروژه را به یک چارچوب در مقیاس درس پیشرفته تبدیل می‌کند. ارتقاها‌ی اصلی شامل چهار الگوریتم (CQL، IQL، SAC-Lagrangian، PPO-Lagrangian) پشته‌ی ایمنی ترکیبی (کنترل‌گر PID، سپر تصمیم‌درختی، منتقد ریسک مسیر)، سه خانواده سناریوی محیطی (عادی، اغتشاش‌یافته، خصمانه)، سامانه‌ی پیکربندی YAML با سازگاری عقب‌رو، CLI و خط لوله‌ی بنچمارک/چاروب PID است. نتایج نهایی شامل منحنی‌های پارتو، تحلیل ایمنی زمانی، و ارزیابی آستانه‌های چندسطحی است.

I. مقدمه

در کاربردهای ایمنی‌حساس، کیفیت یک عامل RL فقط با پاداش اندازه‌گیری نمی‌شود، بلکه باید همزمان سه پرسش پاسخ داده شود:

- (۱) آیا با داده‌ی آفلاین می‌توان شروع پایدار داشت؟
 - (۲) آیا گذار آفلاین به آنلاین بدون واگرایی ایمنی انجام می‌شود؟
 - (۳) آیا رفتار عامل در سناریوهای مخدوش قابل‌اعتماد باقی می‌ماند؟
- نسخه‌ی v2 برای پاسخ عملی به این سه محور طراحی شده است.

II. دامنه‌ی پیاده‌سازی

در مسیر projects/amasa_clean موارد زیر پیاده‌سازی شده‌اند:

- ماژول‌های جدید: offline, envs, amasa/core, bench safety, online,
- درخت تنظیمات: 'scenarios', 'algorithms', 'configs/base', 'thresholds', 'sweep', 'presets'
- حفظ اسکرپت‌های قبلی با فلگ‌های جدید --preset --config --algo --scenario
- رانر یکپارچه run_experiment.py
- تست واحد و اسموک
- گزارش انگلیسی و فارسی در قالب IEEE

III. معماری

آ. لایه‌های اصلی

- لایه تنظیمات: بارگذاری، ادغام و اعتبارسنجی YAML
- لایه محیط: دینامیک پایه + سناریوهای تنش
- لایه یادگیری: الگوریتم‌های آفلاین و آنلاین
- لایه ایمنی: تجمیع منتقد ریسک + سپر + PID
- لایه ارزیابی: اجرای ماتریس، تجمیع، نمودار و بررسی آستانه

ب. ترتیب ادغام پیکربندی


ترتیب ادغام برای جلوگیری از ناسازگاری زمان اجرا:

base → scenario → algo → preset


با این ترتیب، پرست smoke/full در پایان اعمال می‌شود و بودجه‌ی اجرا حفظ می‌گردد.

جدول I: میانگین پاداش/هزینه در benchmark_summary.csv

الگوریتم	سناریو	پاداش میانگین	هزینه میانگین
CQL	Nominal	۲۸,۵۹۴	۰.۹۶۰
CQL	Perturbed	۰.۴۴۰	۱۱۸.۰
IQL	Nominal	۷۷,۴۳۹	۰.۵۷۰
IQL	Perturbed	۹۱,۷۴۶	۰.۹۹۰
SAC-Lag	Nominal	۴۰,۲۲۷	۹۰.۸۰
SAC-Lag	Perturbed	۹۵.۵۰	۷۳۰.۰
SAC-Lag	Adversarial	۹۶.۲۳۶	۶۱۶.۰
PPO-Lag	Nominal	۲۶,۲۱۸	۷۸۸.۰
PPO-Lag	Perturbed	۹۵.۲۰۳	۹۱۸.۰
PPO-Lag	Adversarial	۱۶,۹۴۰	۷۹۷.۰



شکل ۳: تحلیل جاروب PID روی شبکه‌ی توسعه‌یافته



شکل ۴: نمودار زمانی λ ، امتیاز ریسک و نرخ بلوک‌شدن

د. تحلیل زمانی ایمنی

IX. تحلیل آستانه‌ها


از خروجی benchmark_thresholds.csv:

- stretch: ۸ مورد
- target: ۳ مورد
- minimum: ۲ مورد
- below_min: ۱۷ مورد
- offline_gate_pass: ۷ مورد
- offline_gate_fail: ۵ مورد


نتیجه‌ی فنی: بخش آفلاین در پرست smoke قابل قبول است، اما فاز آنلاین امن هنوز به تنظیم دقیق‌تر و احتمالاً بودجه‌ی آموزشی بزرگ‌تر نیاز دارد.

X. جمع‌بندی

AMASA-Complex v۲ با حفظ سازگاری CLI قبلی، پروژه را به یک چارچوب واقعی‌تر برای تمرین safe RL offline-to-online تبدیل کرده است. مسیر کدنویسی، تست، ارزیابی و گزارش‌دهی یکپارچه شده و تحلیل‌های پارتو و PID نشان می‌دهد که کیفیت سیاست به‌شدت به تنظیم کنترل‌گر ایمنی و سناریوی محیط وابسته است. این دقیقاً همان نقطه‌ی آموزشی مورد نیاز برای پروژه‌های ایمنی‌حساس است.



شکل ۱: پارتوی کلی پاداش-هزینه



شکل ۲: منحنی پاداش-هزینه به تفکیک سناریو

ب. جاروب PID توسعه‌یافته

طبق بازه‌ی درخواستی:

$$k_p \in \{0.4, 0.5, 0.55, 0.6, 0.7\}, \quad k_d \in \{0.05, 0.08, 0.10, 0.12\}, \quad k_i = 0.08$$

تعداد کل اجراها: ۲۰.

VIII. نتایج

آ. خلاصه بنچمارک

ب. نمودارهای پارتو

ج. نتایج جاروب PID

بهترین تنظیم‌ها بر اساس امتیاز مرزی (reward - 300 × cost):

- $k_p = 0.60, k_d = 0.08$: پاداش ۶۵.۴۱۹، هزینه ۶۸۵.۰
- $k_p = 0.55, k_d = 0.10$: پاداش ۷۰.۴۱۲، هزینه ۶۹۸.۰
- $k_p = 0.70, k_d = 0.10$: پاداش ۷۹.۳۶۳، هزینه ۸۴۸.۰